

PROJETO APLICADO

APRESENTAÇÃO E OBJETIVOS

O Projeto Aplicado tem como objetivo desenvolver um processo de **análise, visualização e preparação de dados**, utilizando os conceitos e ferramentas estudados ao longo da disciplina, especialmente as bibliotecas **Pandas, Matplotlib e Scikit-Learn**. A partir de um conjunto de dados real, o grupo deverá identificar um problema ou questão de interesse, **explorar os dados, avaliar sua qualidade, realizar transformações necessárias** e discutir como esses dados poderiam ser utilizados posteriormente em uma aplicação de Inteligência Artificial. Mais do que executar comandos ou produzir gráficos, espera-se que o grupo seja capaz de **justificar suas escolhas, interpretar os resultados obtidos** e comunicar de forma clara as principais conclusões da análise.

Ao concluir o projeto, espera-se que o grupo seja capaz de:

- selecionar e caracterizar um conjunto de dados real, compreendendo seu contexto e formulando uma pergunta analítica que oriente a investigação;
- explorar e visualizar os dados, selecionando técnicas e representações gráficas adequadas e interpretando os resultados obtidos;
- avaliar criticamente a qualidade dos dados, identificando e analisando problemas como valores faltantes, inconsistências, duplicidades e possíveis outliers;
- aplicar e justificar técnicas de codificação de atributos categóricos, preparando-os para possível utilização em algoritmos de aprendizado de máquina;
- organizar e documentar adequadamente o processo de análise desenvolvido em Python;
- comunicar os resultados de forma clara, articulada e tecnicamente fundamentada.

ORGANIZAÇÃO

O projeto poderá ser realizado em **grupos de até 5 participantes**. Exceções quanto ao número de integrantes deverão ser **comunicadas previamente e aprovadas pela professora**. **Todos os integrantes** deverão participar da apresentação em vídeo e **demonstrar conhecimento** sobre a análise realizada pelo grupo.

ENTREGÁVEIS

DATA DE SUBMISSÃO: 27 de setembro de 2026

AVALIAÇÃO: 10,0

	Entregável	Especificação
1	Vídeo de apresentação	Vídeo com duração máxima de 12 minutos, com participação de todos os integrantes. Deverá apresentar o problema investigado e o conjunto de dados utilizado; explicar as principais decisões tomadas durante a análise; apresentar e interpretar os resultados mais relevantes; discutir problemas encontrados na qualidade dos dados; apresentar as transformações realizadas; sintetizar as conclusões e indicar limitações da análise e possíveis aplicações futuras dos dados.
2	Notebook Jupyter ou código Python	Entregar o código utilizado para desenvolver o projeto, preferencialmente em formato .ipynb. O material deverá apresentar: identificação e contextualização do problema; origem e descrição do conjunto de dados; código utilizado nas diferentes etapas; gráficos e análises produzidos; interpretação dos principais resultados; análise da qualidade dos dados; transformações realizadas; síntese dos resultados e resposta à pergunta analítica central; limitações identificadas e, quando pertinente, possíveis aplicações futuras.
3	Slides	Entrega opcional. Deverão ser enviados caso tenham sido utilizados como apoio na apresentação em vídeo.

Os arquivos deverão ser submetidos na tarefa disponibilizada no Moodle, no módulo Geral, Entrega do Vídeo e material do Projeto. [Acesse o link](#)

ESTRUTURA DO PROJETO

O projeto está organizado em **quatro etapas principais**. Os resultados dessas etapas deverão estar presentes no notebook e sintetizados de forma articulada no vídeo.

1. DEFINIÇÃO DO PROBLEMA E CONTEXTUALIZAÇÃO COM UM CONJUNTO DE DADOS REAL

OBJETIVO: Selecionar um conjunto de dados real, compreender seu contexto e definir o problema que orientará a análise.

ATIVIDADES: O grupo deverá selecionar um conjunto de dados de interesse, proveniente de uma fonte confiável. Alguns repositórios públicos podem ser utilizados, tais como:

- **Kaggle** - <https://www.kaggle.com/>
- **UCI Machine Learning Repository** <https://archive.ics.uci.edu/>
- **Dados abertos gov.br** - <https://dados.gov.br/dados/conjuntos-dados>
- **Dados abertos POA** - <https://dadosabertos.poa.br/>
- **outros repositórios** ou fontes confiáveis de dados.

Após a escolha do conjunto de dados, o grupo deverá:

1. Apresentar a origem e o contexto dos dados: identificar a fonte e explicar brevemente em que contexto os dados foram produzidos ou coletados, incluindo, quando essa informação estiver disponível, período, população ou domínio representado.
2. Descrever a estrutura do conjunto de dados: informar o número de registros e de atributos, identificar os tipos de dados presentes (numéricos, categóricos, datas etc.) e explicar o significado dos atributos relevantes para a análise.
3. Definir e contextualizar o problema investigado: explicar o que o grupo pretende investigar e por que essa análise é relevante no contexto do conjunto de dados selecionado.
4. Formular pelo menos uma pergunta analítica central que possa ser investigada a partir dos dados disponíveis e que oriente as etapas seguintes do projeto.

Por exemplo:

- Quais características estão mais associadas a determinado resultado?
- Como determinado indicador se distribui entre diferentes grupos?
- Existem diferenças relevantes entre categorias ou períodos?

A pergunta analítica deve ser clara, coerente com os dados disponíveis e passível de investigação por meio das análises realizadas no projeto. Ela deverá funcionar como um fio condutor do trabalho, orientando a seleção das análises e visualizações apresentadas nas etapas seguintes.

ESPERA-SE: Ao final desta etapa, o grupo será capaz de explicar qual é o contexto dos dados, qual problema será investigado, por que ele é relevante e qual pergunta analítica orientará o projeto. A pergunta analítica deverá ser retomada nas

conclusões, indicando quais evidências encontradas nos dados permitem respondê-la, ainda que parcialmente.

2. ANÁLISE EXPLORATÓRIA E VISUALIZAÇÃO DO CONJUNTO DE DADOS

OBJETIVO: Explorar o conjunto de dados utilizando técnicas de visualização para identificar padrões, distribuições, relações e características relevantes.

ATIVIDADES: Realize uma análise exploratória dos atributos utilizando Pandas, Matplotlib e, quando pertinente, outras bibliotecas complementares como Seaborn. A análise deverá combinar medidas descritivas e recursos de visualização, buscando compreender tanto o comportamento individual dos atributos quanto possíveis relações entre eles. No caso de conjuntos com muitos atributos, concentrar a análise nos principais atributos, justificando a seleção. O grupo deverá selecionar aqueles considerados mais relevantes para o problema investigado e justificar essa escolha.

Escolha e construção das visualizações: Os gráficos devem ser selecionados de acordo com o tipo de dado, objetivo da análise e a informação que se deseja comunicar. Algumas possibilidades são:

- atributos categóricos: gráficos de barras para analisar frequências, proporções e balanceamento entre categorias;
- atributos numéricos: histogramas e boxplots para analisar distribuição, dispersão e comportamento dos valores;
- relações entre atributos numéricos: gráficos de dispersão (scatter plots) e análises de correlação;
- relações entre atributos categóricos e numéricos: gráficos que permitam comparar a distribuição de valores entre diferentes grupos ou categorias;
- relações entre múltiplos atributos: mapas de correlação e outras visualizações consideradas adequadas ao contexto dos dados.

Esses exemplos são apenas referências. O grupo poderá utilizar outras representações gráficas, desde que sejam adequadas aos dados e contribuam para a análise proposta.

ESPERA-SE: Ao final desta etapa, o grupo deverá demonstrar capacidade de explorar os dados de forma orientada pelo problema, selecionando técnicas e visualizações adequadas e interpretando corretamente os resultados obtidos. A análise deverá contribuir para responder às questões: O que os dados revelam? Quais são seus principais padrões e características? Quais evidências encontradas ajudam a responder à pergunta analítica definida pelo grupo?

3. ANÁLISE DA QUALIDADE DOS DADOS

OBJETIVO: Identificar e analisar problemas de qualidade que possam comprometer a interpretação dos dados ou sua utilização posterior em análises e aplicações de Inteligência Artificial.

ATIVIDADES: Realize uma análise da qualidade do conjunto de dados, considerando, quando aplicável: dados faltantes; registros duplicados; valores ou registros inconsistentes; tipos de dados inadequados; categorias representadas de formas diferentes; valores impossíveis ou incompatíveis com o domínio do problema; possíveis outliers nos atributos numéricos.

Para os problemas identificados, procure quantificar sua ocorrência em relação ao conjunto de dados. Por exemplo, para dados faltantes, apresente a quantidade e o percentual de valores ausentes por atributo. Para registros duplicados, informe sua quantidade e avalie sua representatividade no conjunto. Além de identificar e quantificar os problemas, discuta seu possível impacto sobre as análises realizadas e sobre uma futura utilização dos dados em aplicações de IA. Na análise de outliers, indique o critério ou método utilizado para identificar valores potencialmente atípicos e discuta os principais resultados encontrados.

Importante: a identificação de um outlier não implica automaticamente sua remoção. Valores extremos podem representar erros, mas também podem corresponder a situações reais e relevantes para o problema investigado. Qualquer decisão de tratamento deve considerar o contexto dos dados. Para os principais problemas encontrados, indique como o grupo trataria ou investigaria o problema antes de utilizar os dados em etapas posteriores. Quando pertinente, podem ser consideradas estratégias como: remoção de registros ou atributos; correção ou padronização de valores; imputação de valores ausentes; tratamento de registros duplicados; transformação de atributos; ou manutenção dos valores quando houver justificativa para preservá-los.

ESPERA-SE: Ao final desta etapa, o grupo será capaz de responder: Quais problemas de qualidade foram encontrados? Qual é a magnitude de cada problema? Como eles podem afetar os resultados da análise ou uma futura aplicação de IA? Quais estratégias seriam adequadas para tratá-los e por quê?

4. CODIFICAÇÃO DE ATRIBUTOS CATEGÓRICOS

OBJETIVO: Preparar os atributos categóricos para que possam ser utilizados por algoritmos que trabalham com representações numéricas.

ATIVIDADES: Identifique os atributos categóricos relevantes do conjunto de dados e aplique técnicas de codificação estudadas na disciplina, como One-Hot Encoding, Ordinal Encoding ou outras estratégias consideradas adequadas. Para cada atributo selecionado, identifique o tipo de variável categórica, escolha uma técnica de codificação adequada e justifique a escolha considerando o significado das categorias e a existência ou não de uma relação de ordem entre elas. Aplique as transformações e gere uma nova representação do conjunto de dados com os atributos categóricos selecionados convertidos para formato numérico. Apresente as principais diferenças entre os dados antes e depois da codificação, considerando, quando aplicável, aspectos como número de

atributos, tipos de dados, novas colunas geradas e forma de representação das categorias.

ESPERA-SE: Ao final desta etapa, o grupo será capaz de responder: Por que os atributos categóricos precisaram ser transformados? Quais técnicas de codificação foram utilizadas e por quê? Como as transformações modificaram a estrutura dos dados?

AVALIAÇÃO

A avaliação, no valor total de 10,0 pontos, será realizada com base no vídeo e no notebook/código entregues pelo grupo, considerando tanto o desenvolvimento técnico quanto a qualidade da comunicação.

CRITÉRIO	DESCRIÇÃO	PONTOS
Definição do problema e contextualização dos dados	Origem e contexto dos dados; caracterização do conjunto; definição do problema; relevância da análise; formulação e adequação da pergunta analítica central.	1,5
Análise exploratória e visualização dos dados	Seleção dos atributos; adequação das técnicas e visualizações; justificativa das escolhas; qualidade dos gráficos; identificação de padrões e relações; interpretação dos resultados e conexão com a pergunta analítica.	2,5
Análise da qualidade dos dados	Identificação e quantificação de dados faltantes, duplicidades, inconsistências e possíveis outliers; discussão dos impactos; proposição de estratégias de tratamento coerentes e justificadas.	2,0
Codificação dos atributos categóricos	Identificação dos atributos categóricos; escolha e aplicação adequada das técnicas de codificação; justificativa das escolhas; comparação e interpretação das transformações realizadas.	1,5

Qualidade técnica e organização do notebook/código	Organização e legibilidade do notebook; sequência lógica das análises; uso adequado das bibliotecas e técnicas; presença de explicações que permitam compreender e reproduzir o processo realizado.	1,0
Apresentação e domínio do projeto	Clareza, objetividade e capacidade de síntese; qualidade do material de apresentação; participação de todos os integrantes e demonstração de domínio das análises, técnicas e decisões realizadas.	1,5
	TOTAL	10,0

ORIENTAÇÕES GERAIS

Organização e reprodutibilidade: O notebook deverá ser entregue organizado e executado, apresentando os resultados das células de código e das visualizações produzidas. O código deverá estar estruturado de forma que seja possível compreender a sequência das etapas realizadas pelo grupo. A fonte do conjunto de dados deverá ser claramente informada. Sempre que possível, inclua no notebook o endereço para acesso aos dados. Caso o conjunto não esteja disponível publicamente ou dependa de um arquivo específico, inclua também o arquivo necessário para a execução do projeto.

O notebook deverá combinar código, resultados e explicações, permitindo compreender não apenas quais procedimentos foram realizados, mas também as principais decisões tomadas durante a análise.

Uso de ferramentas de Inteligência Artificial Generativa: É permitido utilizar ferramentas de Inteligência Artificial Generativa, como ChatGPT, GitHub Copilot e similares, como apoio ao desenvolvimento do projeto. O uso dessas ferramentas não substitui a responsabilidade do grupo sobre o conteúdo entregue. Todos os integrantes deverão ser capazes de compreender, explicar e justificar o código, as técnicas, as análises e as conclusões apresentadas, independentemente de terem utilizado ferramentas de IA durante sua elaboração.

Caso sejam utilizadas ferramentas de IA Generativa, o grupo deverá incluir, ao final do notebook, uma breve declaração indicando quais ferramentas foram utilizadas e para quais finalidades, por exemplo: apoio à compreensão de código, geração ou revisão de trechos de código, sugestões de visualização, revisão textual ou apoio à interpretação. A utilização de conteúdo gerado por IA sem compreensão ou sem capacidade de justificativa poderá impactar a avaliação nos critérios relacionados ao domínio técnico e à apresentação do projeto.